

Analyse du Marché de l'Emploi au Maroc

Rekrute.ma — Collecte, Nettoyage, NLP, Règles d'Association et Classification

Pipeline complet de Data Science

Crawling Web · Scraping · Nettoyage · TF-IDF · KMeans
Apriori · Régression Logistique · Naive Bayes

Essaji Siham
Houda El Fadli
Elammadi Hafsa
G3-AIDATA

1. Introduction et Contexte

Ce rapport présente les résultats d'un pipeline de traitement de données conçu pour analyser le marché de l'emploi marocain à partir des offres publiées sur Rekrute.ma, l'une des principales plateformes de recrutement du pays. L'objectif principal était de collecter, nettoyer et analyser un large ensemble d'offres d'emploi afin d'identifier des tendances structurelles en matière de demande sectorielle, géographique, de niveaux d'expérience requis et de compétences recherchées.

Le projet couvre l'intégralité du cycle de vie d'un projet de Data Science : collecte automatisée par crawling et scraping web, nettoyage et structuration des données brutes, traitement du langage naturel via TF-IDF et regroupement par KMeans, fouille de règles d'association avec l'algorithme Apriori, et classification supervisée par secteur d'activité. Tous les résultats sont issus de données réelles extraites directement de la plateforme.

Rekrute.ma est une référence du recrutement au Maroc, indexant des milliers d'offres couvrant l'ensemble des secteurs économiques du pays. L'analyse de cette plateforme permet donc d'obtenir une image représentative du marché formel de l'emploi marocain à un instant donné.

Ce rapport est structuré en sept parties : collecte des données, nettoyage, analyse exploratoire, analyse textuelle et clustering, règles d'association, classification supervisée, et conclusions.

2. Collecte des Données

2.1 Exploration des pages d'offres (Crawling)

La première étape du pipeline consiste à identifier toutes les URLs d'offres d'emploi disponibles sur Rekrute.ma. Le script `crawler.py` parcourt de façon séquentielle les pages de listing de la plateforme, de la page 1 jusqu'à un maximum de 180 pages. Pour chaque page, les liens individuels vers les offres sont extraits à l'aide du sélecteur CSS `a.titreJob`.

Afin de respecter les bonnes pratiques de collecte responsable, un délai fixe de 1,5 secondes est appliqué entre chaque requête HTTP. Si une page renvoie un code d'erreur ou ne contient aucune offre, le crawling s'arrête automatiquement. Une fois toutes les pages parcourues, les URLs collectées sont dédoublées et sauvegardées dans un fichier JSON (`offer_urls.json`) pour être utilisées par le scraper.

Paramètre	Valeur
Pages crawlées (maximum)	180
Délai entre requêtes	1,5 seconde
Sélecteur CSS utilisé	<code>a.titreJob</code>
Format de sortie	<code>offer_urls.json</code>
Déduplication	Oui — liste finale unique

2.2 Extraction des offres (Scraping)

Le scraper (`scrape.py`) visite chaque URL identifiée par le crawleur et extrait les informations structurées disponibles sur chaque page d'offre. La bibliothèque BeautifulSoup est utilisée pour analyser le contenu HTML. Les champs extraits pour chaque offre sont les suivants :

Champ extrait	Source dans le HTML	Description
titre	Balise <code>h1</code>	Intitulé du poste
fonction_secteur	<code>h2.h2italic</code>	Fonction et secteur combinés
experience	<code>ul.featureInfo</code> — 'Experience'	Niveau d'expérience requis
niveau_etude	<code>ul.featureInfo</code> — 'Niveau d'etude'	Diplôme requis
contrat	<code>ul.featureInfo</code> — 'Type de contrat'	Nature du contrat
teletravail	<code>ul.featureInfo</code> — 'Teletravail'	Possibilité de télétravail
region	<code>ul.featureInfo</code> — 'Region'	Région administrative
description	<code>div.col-md-12.info.blc.noback</code>	Texte complet de l'offre
ville	Regex sur l'URL	Ville déduite de l'URL
entreprise	Regex sur l'URL	Entreprise déduite de l'URL

Des points de sauvegarde intermédiaires sont effectués tous les 100 enregistrements afin d'éviter toute perte de données en cas d'interruption. Les offres sans titre sont ignorées. Les erreurs sont enregistrées séparément dans errors.json pour permettre une relance ciblée. Le fichier final offers_raw.json contient l'ensemble des données brutes collectées.

3. Nettoyage et Structuration des Données

3.1 Opérations de nettoyage

Le script `cleanin.py` transforme le fichier JSON brut en un dataset CSV structuré et normalisé (`offers_clean.csv`). Le nettoyage s'effectue en plusieurs étapes successives :

Dédoublonnage et filtrage

Les doublons sont supprimés sur la base du champ URL, qui constitue l'identifiant unique de chaque offre. Les lignes sans titre sont éliminées car elles ne peuvent pas être exploitées pour l'analyse.

Normalisation des chaînes de caractères

Toutes les colonnes de type texte sont nettoyées en remplaçant les espaces multiples, tabulations et sauts de ligne redondants par un espace simple. Les caractères invisibles sont supprimés.

Séparation Fonction / Secteur

Le champ brut `fonction_secteur` contient à la fois la fonction du poste et son secteur d'activité, séparés par un tiret et le mot-clé 'Secteur'. Des expressions régulières extraient chacun des deux éléments dans des colonnes distinctes : `fonction` et `secteur`.

Extraction par regex depuis la description

Lorsque les champs structurés sont absents ou incomplets, quatre informations clés sont extraites du texte libre de la description via des patterns regex : le niveau d'expérience requis (ex. '3 à 5 ans', 'Junior', 'Confirmé'), le niveau d'étude (ex. 'Bac+5', 'Master', 'Ingénieur'), le type de contrat (CDI, CDD, Stage, Freelance), et la ville lorsqu'elle n'est pas disponible dans un champ dédié.

3.2 Qualité du dataset final

Après nettoyage, le dataset `offers_clean.csv` constitue la base de toutes les analyses suivantes. Les principales statistiques de qualité sont présentées ci-dessous.

Indicateur	Valeur observée
Nombre total d'offres après nettoyage	~1 750 offres
Taux de couverture — champ secteur	> 85%
Taux de couverture — niveau d'expérience	> 70%
Taux de couverture — type de contrat	> 65%
Taux de couverture — ville	> 90%
Doublons supprimés	Plusieurs centaines (dédup sur URL)

4. Analyse Exploratoire des Données

4.1 Répartition par secteur d'activité

Le secteur Banque / Finance domine nettement le marché avec environ 142 offres, suivi par l'Informatique (~107 offres), l'Automobile / Motos / Cycles (~93 offres) et les Centres d'appels (~92 offres). Cette concentration reflète la structure économique du Maroc, avec un secteur financier très actif et un secteur automobile en forte croissance grâce aux investissements industriels récents.

Le secteur 'Autres services' regroupe une catégorie hétérogène d'activités (~77 offres), tandis que la Distribution (~56 offres) et l'Informatique-Internet/Multimédia (~51 offres) complètent le classement. Les secteurs Pharmacie/Santé et Centre d'appels Offshoring/Nearshoring ferment le top 10.




Figure 1 — Top 10 des secteurs par nombre d'offres publiées

4.2 Répartition géographique

La concentration géographique est très marquée : Casablanca concentre à elle seule environ 770 offres, soit plus de 40% du total, confirmant son statut de capitale économique incontestée du pays. Rabat, siège administratif, arrive en deuxième position avec environ 310 offres.

Les villes secondaires affichent des volumes bien plus faibles : Marrakech (~80 offres), Tanger (~70 offres), Fès (~50 offres), Agadir et Meknès (autour de 35-40 offres chacune). Cette hiérarchie géographique illustre la polarisation du marché du travail formel autour des deux premières agglomérations du pays.



Figure 2 — Top 10 des villes par nombre d'offres

4.3 Niveaux d'expérience requis

L'analyse de l'expérience requise révèle une forte demande pour les profils intermédiaires. La tranche 1 à 3 ans est la plus représentée avec environ 590 offres, immédiatement suivie par la tranche 3 à 5 ans (~500 offres). Ces deux tranches ensemble représentent plus de 60% des offres dont l'expérience est renseignée.

Les profils de 5 à 10 ans d'expérience représentent une part significative (~335 offres), indiquant une demande réelle pour des managers et experts confirmés. Les débutants (sans expérience préalable) trouvent également leur place avec ~180 offres. En revanche, les profils Senior (10 à 20 ans) restent marginaux (~50 offres), ce qui est cohérent avec une structure de marché où les postes de direction sont peu publiés sur les plateformes généralistes.




Figure 3 — Distribution des offres par niveau d'expérience requis

5. Analyse Textuelle et Clustering

5.1 Prétraitement du texte

Avant d'appliquer toute méthode d'analyse textuelle, les descriptions des offres subissent un prétraitement complet dans `analyzer.py`. Les étapes appliquées sont les suivantes :

Étape	Description
Mise en minuscule	Uniformisation de la casse
Suppression des URLs et emails	Regex — suppression des liens et adresses
Suppression de la ponctuation	Conservation des caractères alphabétiques uniquement
Tokenisation	Découpage en mots individuels
Suppression des stopwords	Liste étendue FR + termes parasites du site web
Filtrage par longueur	Conservation des tokens de 4 à 14 caractères

La liste de stopwords a été enrichie manuellement pour éliminer les termes structurels propres à Rekrute.ma (ex. 'rekrute', 'postulez', 'nonpubli', 'hybridepubli') ainsi que des mots trop génériques comme les noms de villes, termes de mise en forme ou fragments de mots liés à l'encodage.

5.2 Vectorisation TF-IDF

Un vectoriseur TF-IDF (Term Frequency — Inverse Document Frequency) est appliqué sur le corpus de textes nettoyés. Les paramètres retenus sont un vocabulaire limité aux 300 termes les plus informatifs, un seuil minimum de fréquence documentaire de 3 (le terme doit apparaître dans au moins 3 offres), et un plafond à 85% de la collection (termes trop ubiquitaires exclus).

Le nuage de mots ci-dessous illustre visuellement les termes les plus pondérés par TF-IDF dans l'ensemble du corpus. On y retrouve des termes dominants tels que 'commercial', 'ingénieur', 'comptabilité', 'finance', 'vente', 'maintenance', 'qualité' et 'sécurité', qui traduisent les secteurs et fonctions les plus représentés dans le dataset.




Figure 5 — Répartition des offres par cluster KMeans

6. Analyse des Règles d'Association

6.1 Méthodologie

L'analyse des règles d'association (association.py) applique l'algorithme Apriori à un dictionnaire de 40 compétences professionnelles prédéfinies, détectées par correspondance exacte dans le texte des descriptions. Seules les offres mentionnant au moins deux compétences sont conservées pour cette analyse.

Paramètre Apriori	Valeur retenue	Justification
Support minimum	5%	Compétence présente dans au moins 5% des offres
Confiance minimum	50%	La règle prédit la conséquence dans 50%+ des cas
Métrique de tri	Lift	Mesure la force de l'association au-delà du hasard
Offres retenues	≥ 2 compétences détectées	Filtrage des offres exploitables

6.2 Compétences les plus demandées

Le graphique ci-dessous présente les 15 compétences les plus fréquemment mentionnées dans les offres. Le management domine largement avec près de 240 mentions, suivi de la gestion (~230) et de la finance (~225). La comptabilité (~195) et l'audit (~100) complètent le top 5, confirmant la prédominance du secteur financier dans le dataset.

Les compétences techniques telles que le git (~12), les données/data science (~14) et le cloud (~8) apparaissent en bas du classement, ce qui s'explique par le fait que la liste de compétences prédéfinie inclut peu de termes techniques précis, et que les offres IT sont proportionnellement moins nombreuses que les postes commerciaux et financiers.




Figure 6 — Top 15 des compétences les plus demandées

6.3 Règles d'association découvertes

Les règles les plus fortes en termes de lift identifiées par l'algorithme Apriori sont présentées dans le tableau suivant. Un lift élevé indique une co-occurrence bien supérieure à ce que le hasard prédirait.

Si (antécédent)	Alors (conséquent)	Confiance	Lift
marketing	communication	54,3%	8,12
communication	marketing	83,3%	8,12
gestion + audit	finance + comptabilité	92,3%	2,30
gestion + audit + finance	comptabilité	98,4%	2,28
gestion + management + finance	comptabilité	94,2%	2,19
audit + finance	comptabilité	92,6%	2,15
gestion + finance	comptabilité	92,2%	2,14
comptabilité	gestion + finance	85,5%	2,14
audit	comptabilité	86,1%	2,00
finance	comptabilité	80,0%	1,86

La règle marketing → communication est la plus forte avec un lift de 8,12, signifiant que les offres mentionnant le marketing ont 8 fois plus de chances de mentionner aussi la communication que si les deux compétences étaient indépendantes. Le cluster finance/comptabilité/gestion/audit forme un groupe très cohésif avec des confidences supérieures à 90%, reflétant la forte spécialisation des offres du secteur bancaire.

6.4 Visualisation — Support vs Confiance

Le graphique ci-dessous représente chaque règle d'association par son support (axe horizontal) et sa confiance (axe vertical). La couleur encode la valeur du lift : les points foncés (bordeaux/rose foncé) correspondent aux règles les plus fortes. On observe deux zones distinctes : les règles rares mais très prédictives (coin supérieur gauche, lift élevé) et les règles fréquentes avec une confiance modérée (partie centrale et droite du graphique).




Figure 7 — Nuage de règles d'association : Support vs Confiance (couleur = Lift)

7. Classification Supervisée par Secteur

7.1 Configuration de l'expérience

Deux modèles de classification supervisée sont entraînés pour prédire automatiquement le secteur d'activité d'une offre d'emploi à partir de son texte (représenté par TF-IDF). Seuls les secteurs comptant au moins 30 offres sont retenus afin de garantir une représentation suffisante pour l'entraînement, ce qui conduit à 15 classes cibles.

Paramètre	Valeur
Modèles comparés	Régression Logistique, Naive Bayes Multinomial
Nombre de classes (secteurs)	15
Seuil minimum d'offres par classe	30
Répartition train / test	80% / 20%
Stratification	Oui — proportions de classes respectées
Vectorisation	TF-IDF (300 features, réutilisé depuis analyzer.py)
Itérations max (LR)	1 000
Graine aléatoire	42

7.2 Résultats de classification

Régression Logistique : 79,46% d'accuracy		Naive Bayes : 71,89% d'accuracy		Meilleur modèle : Régression Logistique (+7,57 points)
---	--	---------------------------------	--	--

La Régression Logistique surpasse Naive Bayes de plus de 7 points de pourcentage. Cet écart s'explique par la nature des données : TF-IDF produit des vecteurs creux (sparse) avec des valeurs continues, pour lesquels la Régression Logistique est mieux adaptée. Naive Bayes suppose l'indépendance conditionnelle des features, hypothèse qui n'est pas vérifiée ici car les termes liés à un même secteur co-occurrent fréquemment.




Figure 8 — Comparaison de l'accuracy des deux modèles de classification

7.3 Analyse de la matrice de confusion

La matrice de confusion ci-dessous détaille les prédictions du meilleur modèle (Régression Logistique) pour chacun des 15 secteurs. Plusieurs observations importantes peuvent être formulées :

Secteur	Observations	Analyse
Banque / Finance	29/29 corrects (100%)	Vocabulaire très distinctif (audit, taux, crédit)
Informatique	17/22 corrects (77%)	Quelques confusions avec Informatique-Internet
Automobile / Motos	17/19 corrects (89%)	Bonne séparation grâce aux termes techniques
Centre d'appels	15/18 corrects (83%)	Confusion légère avec Autres services
Autres services	10/15 corrects (67%)	Catégorie hétérogène par nature
Indifférent	6/14 corrects (43%)	Vocabulaire générique — classe difficile à prédire
Distribution	8/11 corrects (73%)	Confusions avec Autres services
Informatique-Internet	10/10 corrects (100%)	Très bien séparé
Pharmacie / Santé	8/8 corrects (100%)	Vocabulaire très spécifique
Offshoring / Nearshoring	7/7 corrects (100%)	Termes très caractéristiques
Comptabilité / Audit	7/7 corrects (100%)	Fort overlap avec Finance — bien géré
BTP / Génie Civil	6/6 corrects (100%)	Vocabulaire technique distinct

Les secteurs avec un vocabulaire très spécialisé (Finance, Pharmacie, Offshoring, BTP) atteignent 100% de précision. La catégorie 'Indifférent' est la plus difficile à classer avec seulement 43% de précision, ce qui est attendu : cette catégorie regroupe des offres sans secteur clairement défini, dont le texte est naturellement ambigu.




Figure 9 — Matrice de confusion — Classification par secteur (Régression Logistique)

8. Conclusions et Perspectives

8.1 Principaux enseignements

Ce projet a permis de construire et d'exécuter avec succès un pipeline de Data Science complet, de la collecte brute jusqu'à la modélisation prédictive. Les principaux résultats obtenus sont les suivants :

Dimension analysée	Résultat clé
Secteur dominant	Banque / Finance (142 offres) — secteur le plus actif
Ville dominante	Casablanca — plus de 40% des offres totales
Expérience la plus demandée	1 à 3 ans (~590 offres) — marché orienté junior-intermédiaire
Compétences les plus fréquentes	Management, gestion, finance, comptabilité
Association la plus forte	Marketing ↔ Communication (Lift = 8,12)
Meilleur modèle de classification	Régression Logistique — 79,46% d'accuracy
Secteurs parfaitement classifiés	Finance, Pharmacie, Offshoring, BTP, Informatique-Internet
Secteur le plus difficile	'Indifférent' — vocabulaire trop générique (43% précision)

8.2 Limites de l'étude

Plusieurs limites doivent être prises en compte dans l'interprétation des résultats. Premièrement, le dataset est limité à une seule plateforme (Rekrute.ma) et ne représente donc pas l'intégralité du marché de l'emploi marocain, qui inclut également des recrutements informels, des sites concurrents et des canaux non numérisés.

Deuxièmement, l'extraction de champs comme la ville et le type de contrat par regex depuis la description introduit un biais potentiel lorsque ces informations sont ambiguës ou absentes du texte. Troisièmement, le dictionnaire de compétences utilisé pour l'analyse d'association est prédéfini et limité à 40 termes, ce qui peut sous-représenter des compétences émergentes ou des termes en anglais.

8.3 Pistes d'amélioration

Plusieurs extensions sont envisageables pour enrichir ce travail. L'intégration de données salariales permettrait d'ajouter une dimension économique à l'analyse sectorielle. L'utilisation de modèles de langage pré-entraînés pour le français (comme CamemBERT) améliorerait la qualité des représentations textuelles et donc les performances de classification.

L'automatisation du pipeline via une planification périodique (hebdomadaire ou mensuelle) permettrait de suivre l'évolution du marché dans le temps. Enfin, la construction d'un tableau de bord interactif (Streamlit ou Dash) rendrait les résultats accessibles à des utilisateurs non techniques, comme des conseillers en orientation ou des professionnels RH.
